Indonesia AI
AI for Everyone, AI for Indonesia

Project 1

Sentiment Analysis

Use Case : Pilpres 2019

March 2025
Group C – Batch 10 NLP

Background

Beragam sentimen masyarakat terhadap pelaksanaan Pilpres 2019 tersebar luas di media sosial, khususnya Twitter, dan sering diasumsikan bersifat negatif. Namun, persepsi tersebut ***perlu divalidasi untuk mengetahui apakah sentimen publik didominasi oleh sentimen negatif atau justru banyak sentimen positif.*** *Oleh karena itu, bisa dilakukan analisis sentimen sebagai dasar evaluasi yang objektif.*

source : twitter.com

Project Overview

*Berikut adalah **gambaran singkat dari project yang akan dilakukan**:*

Project Description

Proyek ini **bertujuan melakukan analisis sentimen terhadap data Twitter terkait Pilpres 2019** untuk memahami persepsi publik serta **mengembangkan model analisis sentimen yang dapat digunakan pada pemilu presiden berikutnya.**

Project Method

Pada proyek ini digunakan **algoritma Random Forest dan LSTM,** disertai dengan **proses hyperparameter tuning** untuk mengoptimalkan kinerja masing-masing algoritma.

Project Output

Proyek ini mencakup **evaluasi kinerja model guna menentukan algoritma yang paling efektif** untuk analisis sentimen.

Business Objective

Hasil dari proyek ini diharapkan dapat memberikan manfaat bisnis, antara lain:

- **Mengukur distribusi dan tren sentimen publik secara objektif** terhadap pelaksanaan Pilpres 2019.
- **Mengidentifikasi isu dan perhatian utama masyarakat** pada masing-masing kategori sentimen (positif, netral, dan negatif), sehingga dapat menjadi dasar evaluasi dan perbaikan pada penyelenggaraan pemilu di masa mendatang.

Project Member

Indonesia AI
AI for Everyone, AI for Indonesia

1

Irfan Gani Alim

2

Khaerani **Arista** Dewi

3

Agil Setiawan

4

Krisna **Fery** Rahmantya

5

Surya Dharma Putra

Project Flow

Indonesia AI
AI for Everyone, AI for Indonesia

1 Data & Business Understanding

Data Understanding & EDA	Exploratory Data Analysis for Sentiment Analysis
Contextual Understanding of the Dataset	Sentiment Distribution Analysis (Balance / Imbalanced)
Identification of Missing and Duplicate Data	Frequent Terms Analysis (Unigram & Bigram)
Text Length Analysis	

2 Data Preprocessing

Text Cleaning	Text Normalization
Stopword - Negasi + Kata yang paling sering muncul	Split data Train,Val, Test

3 Data Modeling & Vectorization

Data Modeling	Data Vectorization
Random Forest	TF IDF (untuk representasi token dalam sparse matrix)
LSTM	Label Encoding (Label) & Embedding (representasi vektor dense)

4 Hyper Parameter Tuning

Random Forest	LSTM
n_gram, df_min, max_df, max_features	emb_dim, lstm_units, dense_units, dropout, learning_rate

5 Model Evaluation

Model Evaluation	
Precision	Recall
Accuracy	F1 Score
Confusion Matrix	Plot Loss

Internal

Data Understanding

Distribusi label sudah seimbang, Data right-skewed (persentil-95 untuk membatasi pengaruh outlier), normalisasi typo, slang dan penambahan domain stopword dari hasil unigram dan bigram

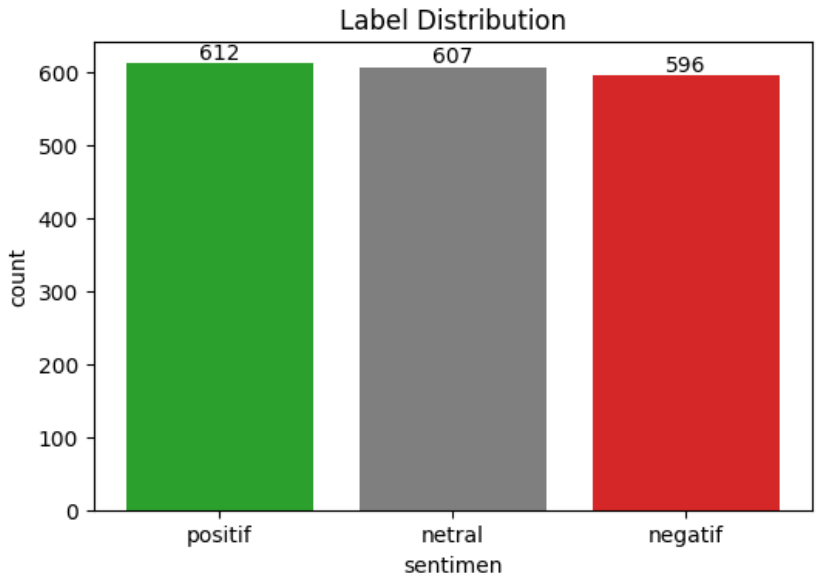

- Distribusi label **cukup seimbang -> akurasi** masih relevan
- Pengunaan Macro F1 (supaya lebih fair) & akurasi sebagai metrik utama
- Histogram terlihat **right- skewed** sehingga supaya pengaruh outlier bisa dikurangi, kita pakai **persentil-95**
- **Mean dan Median** tidak berbeda jauh dan panjangnya moderat
- Dari **unigram dan bigram** terlihat ada slang/typo seperti **"yg"** yang bisa dinormasi jadi 1 token, cleaning terhadap **@ dan #,** dan penambahan stopword untuk **"twitter", "com", "pic", dll** yang tidak informatif

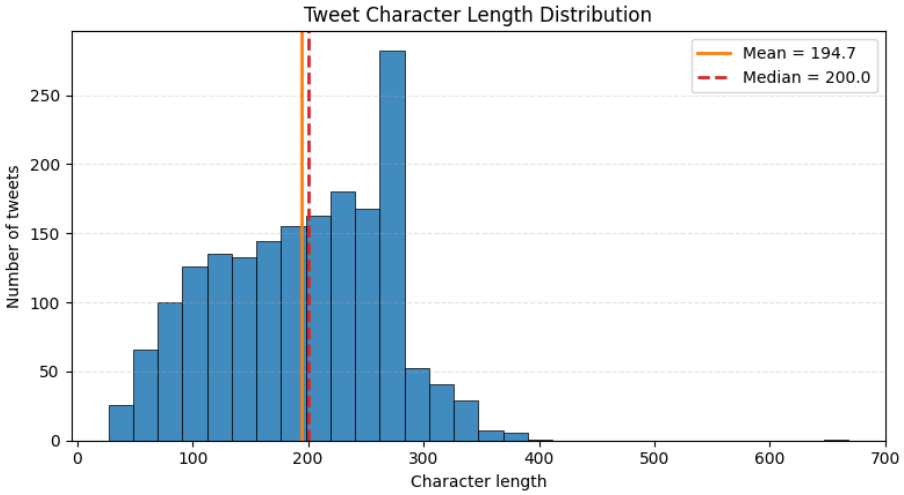

Top 20 Unigram (Overall):

term	freq
ekonomi	927
dan	749
prabowo	708
jokowi	680
yg	666
di	530
pak	480
gaji	447
sandi	388
itu	386
presiden	382
ini	335
yang	326
indonesia	314
akan	298
harga	293
tidak	273
bisa	231
rakyat	210
untuk	198

contoh **typo/slang** "**yg**" bisa diubah menjadi "**yang**"

Top 20 Bigram (Overall):

term	freq
prabowo sandi	274
pic twitter	167
twitter com	167
ambil gaji	126
pak jokowi	121
ekonomi indonesia	110
pak prabowo	93
pertumbuhan ekonomi	78
ekonomi makro	77
pilihjelasislamnya pilihbajuputih	58
pilihorangbaik pilihjelasislamnya	58
tidak akan	56
jika terpilih	55
presiden sebelum	54
akan ambil	48
saat ini	47
mobile legend	46
sebelum jokowi	46
tusuk prabowo	44
jadi presiden	42

Domain stopword seperti "**pic**", "**twitter**" yang kurang informatif seperti "**pic**" yang residu gambar

Sisa "#" yang **bisa dihapus dan diambil** langsung daja isinya

Data Preprocessing

Indonesia AI
AI for Everyone, AI for Indonesia

4 Tahapan dalam proses data preprocessing, diantaranya adalah:

1. Persiapan Kamus & Aturan

- **Modifikasi Stopword:** Mempertahankan kata negasi kunci (seperti *"tidak", "bukan", "jangan"*) agar makna sentimen tetap utuh.
- **Pembersihan Noise Platform:** Membuang token khusus dari platform seperti *"rt", "tco", "amp"* dari kumpulan stopwords.
- **Kamus Normalisasi:** Menyiapkan tabel pemetaan khusus untuk mengubah ejaan tidak baku menjadi bahasa Indonesia baku (contoh: *"yg"* → *"yang"*).

2. Pembersihan Teks Dasar

- **Case Folding:** Menyeragamkan seluruh karakter teks menjadi huruf kecil (lowercase).
- **Noise Removal:** Menghapus elemen tanpa nilai semantik seperti tautan URL dan mention akun Twitter (@username).
- **Hashtag Extraction:** Menghilangkan simbol pagar (#) namun tetap mempertahankan teks kata di belakangnya.
- **Punctuation & Whitespace:** Membuang karakter non-alfanumerik dan merapikan spasi ganda.

3. Pemrosesan Tingkat Kata

- **Tokenisasi & Normalisasi:** Memecah kalimat menjadi token dan mengubah kata slang menjadi baku menggunakan kamus yang telah dibuat.
- **Koreksi Word Elongation:** Menyingkat huruf yang diketik berulang secara berlebihan (contoh: *"baguuuus"* → *"baguus"*).
- **Filtering Panjang Kata:** Membuang kata yang terlalu pendek (< 2 huruf) atau terlalu panjang (> 30 huruf).
- **Stopword Removal:** Menghapus kata umum yang kurang bermakna, sambil memproteksi kata negasi.

4. Pembagian Data (Splitting)

- **Data Train (80%):** Porsi dataset terbesar yang dialokasikan khusus untuk proses pelatihan model machine learning.
- **Data Validation (10%):** Dataset untuk melakukan tuning parameter dan evaluasi selama proses pelatihan.
- **Data Test (10%):** Dataset uji akhir untuk mengukur performa objektif pada data yang tidak pernah dilihat model.
- **Stratified Sampling:** Distribusi porsi label sentimen dipastikan seimbang di setiap subset data (Train, Val, Test).

Internal

Data Modeling & Vectorization

Mengubah data teks menjadi representasi numerik yang dapat dipahami oleh algoritma Machine Learning dan Deep Learning untuk meningkatkan efektivitas model dalam mengenali pola sentimen

Model	Vectorization	Karakteristik Utama	Model Configuration
Random Forest	TF IDF	Menggunakan frekuensi kata terhadap korpus, tapi mengabaikan konteks antar kata, cocok untuk model ML klasik seperti random forest	**Random Forest Baseline** • **TF-IDF: unigram + bigram (ngram_range=(1,2))** Menangkap kata tunggal dan pasangan kata agar model bisa mengenali konteks lokal sederhana. • **min_df = 2 & max_df = 0.90** Membuang token yang terlalu sering muncul dan terlalu jarang muncul untuk mengurangi noise • **sublinear_tf=True** Mengubah frekuensi kata ke skala log agar kata yang sangat sering muncul dalam satu tweet tidak terlalu mendominasi bobot. • **n_estimators=300** Menggunakan 300 pohon agar prediksi lebih stabil sebagai baseline. • **class_weight = "balanced"** Membantu model memberi perhatian yang lebih seimbang pada tiap kelas. • **random_state=42** Menjaga hasil eksperimen tetap konsisten dan reproducible. 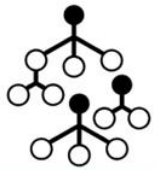

LSTM	Tokenizing + Sequence Encoder (Embedding)	Memanfaatkan vektor padat dengan urutan kata untuk menangkap makna dan konteks, ideal bagi untuk LSTM	**LSTM Baseline**
			• **Tokenizer + Sequence Encoding** (oov_token="<OOV>")
			Teks diubah menjadi urutan indeks integer, lalu kata diluar vocab dianggap sebagai token khusus
			• **Padding + Truncating : max_len=29 (p95)**
			Panjang input diseragamkan untuk menghindari padding berlebihan akibat outlier
			• **LSTM Baseline**
			  • Embedding 128 -> representasi vector dense selama training
			  • LSTM 64 unit -> menangkap urutan kata dan konteks
			  • Dense 64 unit + ReLU -> memggabungkan hasil LSTM sebelum diteruskan ke output layer
			  • Dropout 0.3 -> membantu mengurangi ovefitting
			• **Training Setup**
			  • **Optimizer** : Adam (lr=0.001) -> lebih stabil dan umum dipakai di DL
			  • **Loss :** Sparse Categorical Crossentropy -> klasifikasi multikelas
			  • Epoch 30, batch size 32 -> memberi ruang untuk model belajar untuk menemukan pola pada data
			  • EarlyStopping (5) + ReduceLROnPlateau (2) -> mengurangi resiko overfitting

Internal

Hypertuning Parameter

Indonesia AI
AI for Everyone, AI for Indonesia

```python
param_dist = {
    # TF-IDF: bantu kurangi noise & improve separation
    "tfidf__ngram_range": [(1, 1), (1, 2)],
    "tfidf__min_df": [2, 3, 5],
    "tfidf__max_df": [0.85, 0.90, 0.95],
    "tfidf__max_features": [20000, 50000, None],

    # RF: atur kapasitas & generalisasi
    "rf__n_estimators": [300, 600, 1000],
    "rf__max_depth": [None, 20, 40, 60],
    "rf__min_samples_split": [2, 5, 10],
    "rf__min_samples_leaf": [1, 2, 5],
    "rf__max_features": ["sqrt", "log2", 0.3, 0.5],
    "rf__class_weight": ["balanced", "balanced_subsample"]
}

search = RandomizedSearchCV(
    estimator=pipe,
    param_distributions=param_dist,
    n_iter=30,
    scoring="f1_macro",
    cv=cv,
    random_state=42,
    n_jobs=-1,
    verbose=2,
    return_train_score=True,
    refit=True
)
```

Random Forest

- **TF-IDF dituning pada:**
  - ngram_range, min_df, max_df, max_features
  - Untuk mengurangi noise, mengontrol sparsity, dan menjaga fitur tetap relevan
- **Random Forest dituning pada:**
  - n_estimators, max_depth, min_samples_split, min_samples_leaf, max_features, class_weight
  - Untuk mengatur kapasitas model dan meningkatkan generalisasi
- **Setup tuning:**
  - RandomizedSearchCV, 30 iterasi, 5-fold stratified CV
  - Metrik utama: **Macro F1**
- **Best tuned config:**
  - TF-IDF: unigram, min_df=3, max_df=0.85, max_features=20000
  - RF: 300 trees, max_depth=60, min_samples_split=5, max_features=log2, class_weight=balanced

Hypertuning Parameter

Indonesia AI
AI for Everyone, AI for Indonesia

LSTM

```python
callbacks = [
    EarlyStopping(
        monitor="val_loss",
        patience=5,
        restore_best_weights=True
    ),
    ReduceLROnPlateau(
        monitor="val_loss",
        factor=0.5,
        patience=2,
        min_lr=1e-5
    )
]
```

```python
history = model.fit(
    X_train_pad, y_train_ids,
    validation_data=(X_val_pad, y_val_ids),
    epochs=30,
    batch_size=cfg["batch_size"],
    callbacks=callbacks,
    verbose=0
)

val_prob = model.predict(X_val_pad, verbose=0)
val_pred = np.argmax(val_prob, axis=1)

val_acc = accuracy_score(y_val_ids, val_pred)
val_f1  = f1_score(y_val_ids, val_pred, average="macro")
```

- **LSTM dituning pada:**
  - emb_dim, lstm_units, dense_units, dropout, learning_rate
  - Untuk mencari kombinasi kapasitas model dan regularisasi yang paling seimbang
- **Training setup:**
  - epochs=30
  - EarlyStopping (5)
  - ReduceLROnPlateau (2)
  - Metrik utama: **Macro F1**
- **Best tuned config:**
  - Embedding 128
  - LSTM 128 unit
  - Dense 32 unit
  - Dropout 0.3
  - Learning rate 0.0005
  - Batch size 32

```python
search_space = [
    {"emb_dim": 64,  "lstm_units": 64,  "dense_units": 32, "dropout": 0.2, "lr": 1e-3, "batch_size": 32},
    {"emb_dim": 64,  "lstm_units": 128, "dense_units": 32, "dropout": 0.3, "lr": 1e-3, "batch_size": 32},
    {"emb_dim": 128, "lstm_units": 64,  "dense_units": 64, "dropout": 0.3, "lr": 1e-3, "batch_size": 32},
    {"emb_dim": 128, "lstm_units": 128, "dense_units": 64, "dropout": 0.4, "lr": 1e-3, "batch_size": 32},
    {"emb_dim": 128, "lstm_units": 64,  "dense_units": 32, "dropout": 0.2, "lr": 5e-4, "batch_size": 32},
    {"emb_dim": 128, "lstm_units": 128, "dense_units": 32, "dropout": 0.3, "lr": 5e-4, "batch_size": 32},
]
```

Model Evaluation (Random Forest)

*Selain adanya **indikasi overfitting**, model random forest juga masih mengalami kesulitan dalam menangkap **sentimen positif** secara konsisten, dimana **sering diartikan menjadi sentimen netral**, begitu juga dengan **sentimen negatif** yang diartikan **menjadi sentiment netral ataupun sebaliknya** sentimen negatif menjadi sentiment netral*

Random Forest (Sebelum Hyper Parameter Tuning)

Parameter	Class	Train	Val	Test
Accuracy	-	0.9986	0.6188	0.5330
Macro F1		0.9986	0.6133	0.5244
Precision	Negatif	1.000	0.6056	0.5211
Recall		1.000	0.7167	0.6271
F1 Score		1.000	0.6565	0.5692
Precision	Netral	0.9979	0.5676	0.4937
Recall		0.9979	0.7000	0.6393
F1 Score		0.9979	0.6269	0.5571
Precision	Positif	0.9980	0.7500	0.6562
Recall		0.9980	0.4426	0.3387
F1 Score		0.9980	0.5567	0.4468

Gap score antara data train dan test sangat besar (-0.4656) **sehingga terdapat indikasi overfitting**

Precision netral rendah **(banyak false positive ke netral).**

Kelas positif punya precision tinggi tapi recall rendah → **model hanya berani memberi label positif saat sangat yakin, akibatnya banyak positif "kelewat" (false negative tinggi).**

Error utama untuk kelas negatif adalah **ketukar dengan netral** (28.8%)

Model cukup sering membuat **sentiment netral menjadi negatif**, terutama di test (26,2%)

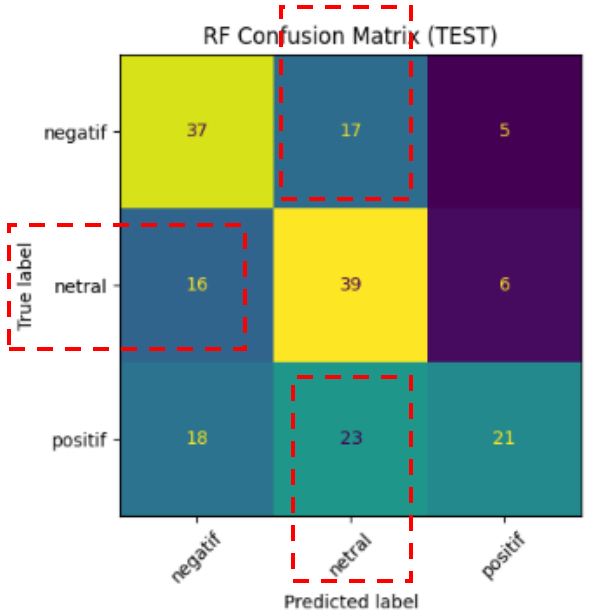

Model cenderung **melembutkan positif menjadi netral**

Model Evaluation (Random Forest)

Pada model Random Forest, ***hyperparameter tuning mengurangi overfitting dan memperbaiki performa di validation****, namun tidak meningkatkan generalisasi di test dan justru* ***meningkatkan kesalahan berisiko, terutama ketika sentimen positif salah diklasifikasikan menjadi negatif.***

Random Forest (Setelah Hyper Parameter Tuning)

Parameter	Class	Train	Val	Test
Accuracy	-	0.9821	0.6409 ↑	0.5055 ↓
Macro F1		0.9821	0.6352 ↑	0.4978 ↓
Precision	**Negatif**	0.9773	0.6301	0.4458 ↓
Recall		0.9937	0.7667	0.6271
F1 Score		0.9854	0.6917	0.5211 ↓
Precision	**Netral**	0.9793	0.6212	0.5469
Recall		0.9753	0.6833	0.5738
F1 Score		0.9773	0.6508	0.5600 ↑
Precision	**Positif**	0.9896	0.6905	0.5714 ↓
Recall		0.9775	0.4754	0.3226 ↓
F1 Score		0.9835	0.5631	0.4124 ↓

Hasil tuning pada random forest berhasil menaikkan **performa pada data val namun turun pada data test,** tapi berhasil mengurangi overfitting

Model **semakin sering salah memberi label negatif** (false positive untuk negatif naik) karena turunnya performansi sentiment negatif.

Tuning tampaknya **menaikkan performansi netral**, tapi mengorbankan sentiment lain

Setelah dilakukan tuning performa turun, hal ini mengindikasikan **sentimen positif sulit tertangkap.**

Tuning **mengurangi kebiasaan negatif jadi netral** (23.7%).

Setelah **tuning justru membuat netral semakin sering salah jadi negative** (31,1%).

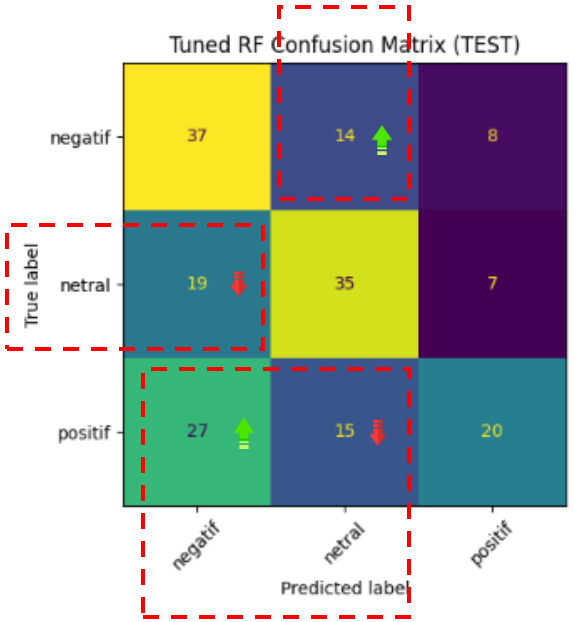

Sentimen negatifnya naik meskipun netralnya turun hal ini justru membuat error yang lebih merugikan

Model Evaluation (LSTM)

*Meskipun secara performa lebih baik dari random forest (gap antara train dan test), namun **LSTM menunjukkan performa generalisasi yang lemah pada data test**, dengan kecenderungan terlalu agresif memprediksi sentimen negatif (recall tinggi namun precision rendah) serta gagal menangkap sentimen positif secara signifikan*

LSTM (Sebelum Hyper Parameter Tuning)

Parameter	Class	Train	Val	Test
Accuracy	-	0.7100	0.5580	0.4670
Macro F1		0.6912	0.5070	0.4140
Precision	Negatif	0.6241	0.5340	0.4180
Recall		0.9434	0.9167	0.8644
F1 Score		0.7513	0.6748	0.5635
Precision	Netral	0.7298	0.5538	0.5957
Recall		0.8004	0.6000	0.4590
F1 Score		0.7635	0.5760	0.5185
Precision	Positif	0.9697	0.7692	0.4615
Recall		0.3926	0.1639	0.0968
F1 Score		0.5590	0.2703	0.1600

LSTM menunjukkan **performa test yang rendah** (Macro F1 0.414) namun dengan **gap accuracy antara train dan test lebih kecil (-0.2430) dibandingkan random forest** meskipun masih terindikasi overfitting

Prediksi **negatif cenderung terlalu agresif** (recall tinggi tapi precision rendah).

Recall dan F1 Score sangat rendah bahkan untuk recall dari **semua data positif, yang berhasil ditangkap hanya sekitar 9.7%**

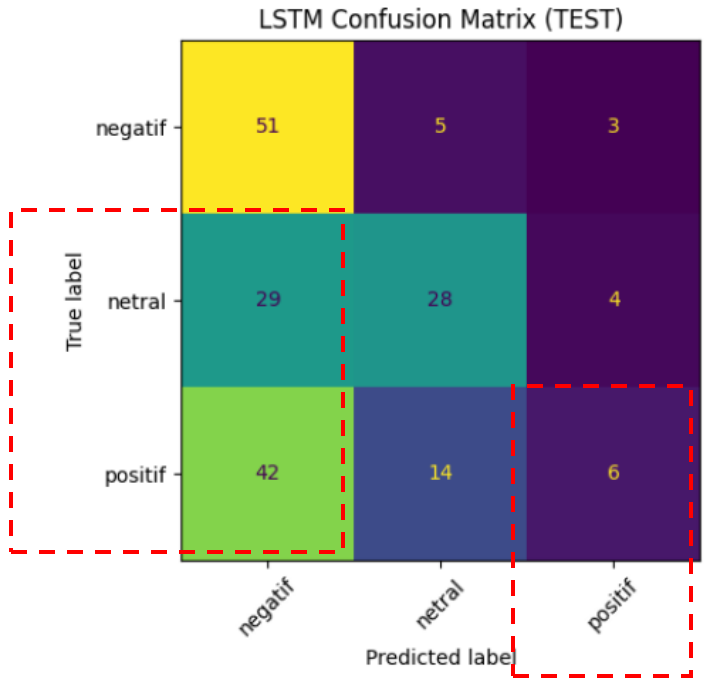

Negatif terlalu agresif sehingga **Beberapa data yang tidak seharusnya negatif banyak diprediksi negatif**

Positif hampir "tidak eksis", Hanya 6 positif tertangkap benar, Mayoritas positif dianggap negatif

Model Evaluation (LSTM)

Setelah hyperparameter tuning, ***LSTM menunjukkan peningkatan performa yang lebih seimbang pada data validasi dan test****, dengan kemampuan yang* ***lebih baik dalam menangkap sentimen positif dan netral****, serta pengurangan bias prediksi berlebih ke kelas negatif."*

LSTM (Setelah Hyper Parameter Tuning)

Parameter	Class	Train	Val	Test
Accuracy	-	0.9001 ↑	0.6298 ↑	0.5385 ↑
Macro F1		0.8988 ↑	0.6197 ↑	0.5297 ↑
Precision	**Negatif**	0.8788	0.6429	0.5316 ↑
Recall		0.9581	0.7500	0.7119 ↓
F1 Score		0.9168	0.6923	0.6087 ↑
Precision	**Netral**	0.8651	0.5946	0.5574 ↓
Recall		0.9630	0.7333	0.5574 ↑
F1 Score		0.9114	0.6567	0.5574 ↑
Precision	**Positif**	0.9770	0.6757	0.5238
Recall		0.7812	0.4098	0.3548 ↑
F1 Score		0.8682	0.5102	0.4231 ↑

Tuning memberikan peningkatan yang konsisten di validation dan test, bukan hanya di train

Model **jadi lebih akurat saat memprediksi negatif** (precision naik). Tapi jadi **lebih sedikit menangkap total kasus negatif (recall turun).**

Meskipun penurunan dari sisi precision, namun **performa netral jadi lebih seimbang** (tidak terlalu condong ke salah satu sisi).

Tuning membuat LSTM jauh lebih bagus menangkap sentiment positif (recall dan F1 naik signifikan)

Hasil tuning jadi lebih baik karena distribusi error lebih seimbang dan positif lebih sering tertangkap

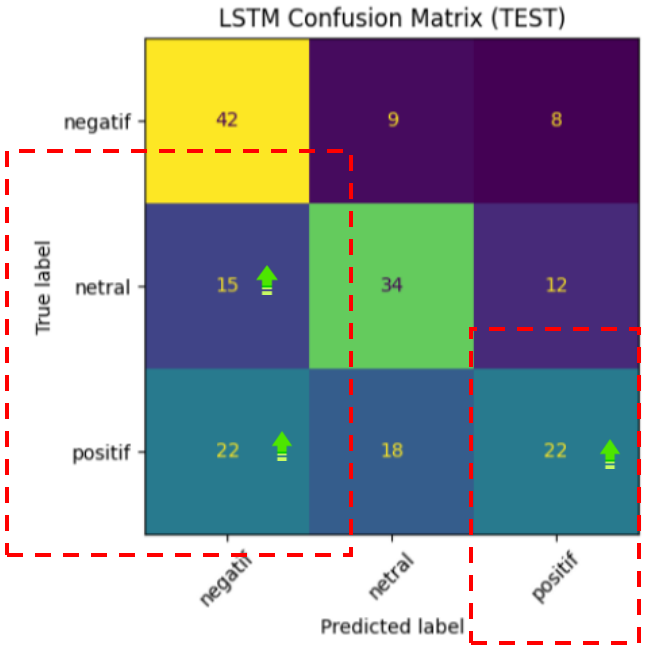

Deteksi positif meningkat signifikan dan error kini lebih seimbang antar kelas

Model Evaluation (LSTM)

*Setelah hyperparameter tuning, **kurva loss dan accuracy LSTM menunjukkan pembelajaran yang lebih stabil dan optimal**, dengan validation accuracy yang meningkat lebih cepat dan mencapai level lebih tinggi dibandingkan model sebelum tuning, meskipun terdapat indikasi penurunan tipis di epoch akhir.*

Plot Loss LSTM Sebelum Hyper Parameter Tuning

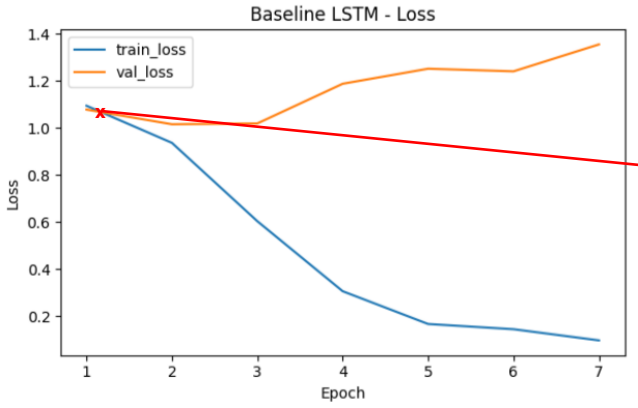

Plot Loss LSTM Setelah Hyper Parameter Tuning

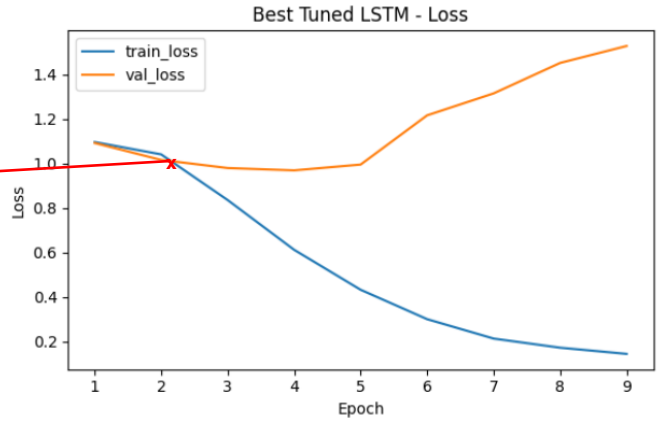

Validation loss terlihat lebih stabil lebih lama (kenaikan terjadi lebih lambat)

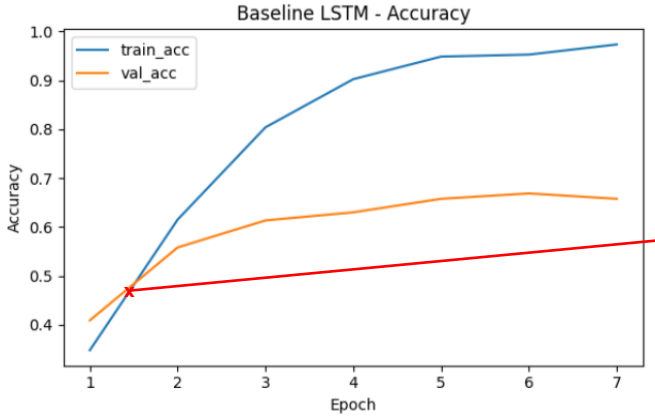

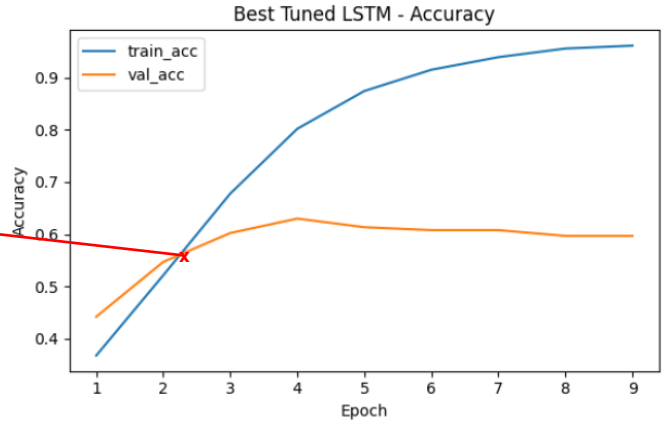

Validation accuracy naik lebih cepat dan lebih tinggi, namun kemudian melandai/menurun tipis di epoch akhir

Internal

Kesimpulan & Rekomendasi

Tuned LSTM memberikan performa yang lebih seimbang dan andal *untuk kasus analisis sentimen Pilpres 2019 pada twitter dibandingkan dengan model random forest, namun untuk Beberapa peningkatan kedepannya perlu dilakukan beberapa hal berikut:*

Kesimpulan

Model Terbaik

- **Tuned LSTM dipilih sebagai model final karena memiliki performa test set yang lebih baik** dibanding Tuned TF-IDF + Random Forest, baik dari sisi accuracy maupun macro F1, sehingga lebih representatif untuk generalisasi opini publik.

Generalisasi Model

- Random Forest unggul pada data train dan validation, **tetapi performanya menurun pada test set**, mengindikasikan generalisasi yang kurang stabil.
- **LSTM menunjukkan performa train yang lebih rendah, namun lebih konsisten pada test set,** sehingga lebih robust terhadap data baru.

Performa Per Kelas

- **Kedua model masih lemah pada sentimen positif,** namun LSTM memiliki recall positif dan negatif yang lebih baik.
- **Random Forest sedikit lebih unggul pada kelas netral**, yang cenderung berbasis kata-kata eksplisit.

Rekomendasi

Evaluasi Model Klasik Tambahan

- **Menguji model klasik lain yang sesuai untuk TF-IDF,** seperti Logistic Regression dan Linear SVM, sebagai pembanding tambahan selain Random Forest.

Penerapan Model Transformer Bahasa Indonesia

- **Mencoba model transformer bahasa Indonesia** (misalnya IndoBERT) untuk meningkatkan pemahaman konteks, terutama pada klasifikasi sentimen positif.

Perbandingan Representasi Teks

- **Mengevaluasi representasi teks alternatif** (Word2Vec atau pretrained embeddings) dan membandingkannya dengan embedding pada LSTM.

Penguatan Arsitektur Sequence-Based

- **Mengembangkan arsitektur sequence-based yang lebih kuat**, seperti BiLSTM atau LSTM dengan Attention, agar lebih peka terhadap urutan dan kata penting.

Analisis Error pada Kelas Netral dan Positif

- **Melakukan analisis error terfokus pada kelas positif ataupun netral** untuk mengidentifikasi pola kesalahan dan memperbaiki preprocessing maupun strategi pemodelan.

Internal

Link Project & Repository

Indonesia AI
AI for Everyone, AI for Indonesia

Link Google Collab:

https://colab.research.google.com/drive/1gy44Qw5XI0IQjnRdOfx2-_Nu9oIsFBe9?usp=sharing

Link Repository:

https://github.com/KamigonNoMercy/twitter_sentiment_classifier

Thank You

Group C – Batch 10 NLP